

AIGC 图像的频谱指纹挖掘与伪造检测

Team members: [fill in]

[fill in]

[fill in], China

[fillin]

Abstract

本文面向课程第五题，研究 AIGC 图像在频率域中的可检测指纹。我们使用 GenImage 中 ADM、BigGAN、VQDM 和 GLIDE 四个生成源，构建两个任务：AI/真实图像二分类，以及 AI 图像生成源归因。方法不依赖 CNN 或 Vision Transformer，而是提取 FFT、DCT、颜色频谱、多尺度频谱、块 DCT 与残差频谱统计，并使用 LightGBM 完成浅层可解释建模。最终主模型为 fusion_freq + flat LightGBM + wide profile，在 full 训练比例下达到二分类 macro-F1 0.9913、AUC 0.9996，归因 macro-F1 0.9991，双任务平均 macro-F1 0.9952。进一步实验表明：频谱融合特征在 clean validation 上极强，但在 JPEG、缩放和高斯噪声等 degraded 场景下明显退化；跨生成器留一测试也显示模型仍会学习到特定生成器的指纹。该结果说明频谱指纹能够有效检测 AIGC 图像，同时鲁棒性与跨生成器泛化仍是关键限制。

1 Introduction

扩散模型和 GAN 生成图像的视觉质量持续提升，单靠肉眼已经难以稳定判断图像来源。课程题目要求从像素空间转向频率空间，挖掘人眼不可见但可统计建模的 AIGC 数字指纹。本文因此不把重点放在语义内容识别，而是研究生成过程、上采样链路、压缩后处理和噪声分布可能残留在频谱中的结构化痕迹。

本文围绕三个问题展开：RQ1，FFT/DCT 等频谱统计能否区分 AI 图像与真实图像；RQ2，频谱特征能否识别生成源；RQ3，JPEG、缩放和噪声扰动会怎样破坏或保留频谱指纹。我们的贡献包括：构建四生成源 GenImage 频谱检测流程；比较 baseline、调参、scale-up 和频域增强路线；加入跨生成器泛化、鲁棒性诊断、置信度拒识和错误模式分析；最终形成一个轻量、可解释、可复现的 AIGC 检测闭环。

2 Dataset and Protocol

本文使用 GenImage 数据集 [3] 中四个生成源子集：ADM、BigGAN、VQDM 和 GLIDE。数据根目录为 C:\Users\99303\git\GenImage\data。每个生成源都包含 train/ai、train/nature、val/ai 和 val/nature。实验中 train 用于训练，val 作为测试集。

二分类任务合并四个生成源下的 AI 与 nature 图像，标签为 ai 和 nature。归因任务只使用 AI 图像，标签为 ADM、BigGAN、VQDM 和 GLIDE。抽样实验均使用分层采样和固定 seed；最终主结果使用 full 训练比例。鲁棒性评估不参与训练，只在同一个 20% validation 子集上施加 JPEG、resize 和 Gaussian noise。

3 Method

基础流程首先将图像 resize 到 256×256 ，对灰度图去均值并施加 Hann 窗，然后计算二维 FFT 功率谱：

$$P(u, v) = \log(1 + |\mathcal{F}(I)(u, v)|^2).$$

baseline 特征包括 FFT 径向功率谱、角向能量、低/中/高频能量比例、频谱斜率、高频残差统计、patch 级高频变化和 DCT 径

Table 1: GenImage 四个生成源的本地数据规模。

Generator	Train AI	Train Nature	Val AI	Val Nature
ADM	162000	157453	6000	6000
BigGAN	162000	162000	6000	6000
VQDM	162000	162000	6000	6000
GLIDE	162000	162000	6000	6000

向谱。为进一步提分，本文实现 fusion_freq profile：在 RGB 与 YCbCr 通道上提取颜色频谱，在 128/256/384 三个尺度上提取多尺度频谱，加入 8x8 block-DCT AC 能量和块边界统计，并对高通、median 与 Laplacian 残差再做频谱统计。所有特征都对明确的信号处理统计，不依赖语义表征。

监督模型以 LightGBM [1] 为主，RandomForest 和 LogisticRegression 作为早期 baseline。最终路线使用 flat LightGBM、多分类归因、wide 参数 profile 和二分类阈值校准。LightGBM 训练优先使用 GPU；若 GPU 在复杂多分类训练中失败，代码自动 fallback 到 CPU。频谱特征提取主要依赖 CPU 多进程和 feature cache。信号处理背景参考 Oppenheim 等人的经典教材 [2]。

4 Experiments

实验分为五层。第一层使用 1%、5% 和 10% 抽样验证原始 FFT/DCT baseline，并完成 LightGBM 调参。第二层进行 20%、50% 和 full scale-up，确认样本量扩大能稳定提升 clean performance。第三层进行频域增强，比较 color_freq、multiscale_freq、block_dct、residual_freq 和 fusion_freq。第四层固定最终模型，在 validation 图像上施加 JPEG、resize 和 Gaussian noise，诊断后处理扰动下的失效模式。第五层扩展分析跨生成器泛化、鲁棒训练、稳健频谱 profile 和置信度拒识。

所有主要结果通过 metrics_summary.json、model_comparison.csv、混淆矩阵、feature importance、robustness CSV 和 confidence CSV 自动汇总到 report/tables 与 report/figures。Notebook 只读取这些资产，不重新执行大规模训练。

5 Results and Analysis

5.1 Clean Performance

表 2 汇总了从旧灰度 baseline 到第二轮频域融合优化的关键结果。第一轮 full baseline 的双任务平均 macro-F1 为 0.9042；引入 fusion_freq 后，5% 抽样已经达到 0.9919，full 训练比例进一步达到 0.9952。最终主结果固定为 outputs_v2_full_best，不把后续鲁棒训练分支替代为主模型。

5.2 Single-Domain and Fused Frequency Results

为了区分“单一频域特征有效”与“融合频域特征更强”这两个结论，本文将第二轮特征实验拆成两类。第一类是单一或局部频域 profile：color_freq 只强调 RGB/YCbCr 颜色通道频谱，




Figure 1: 第二轮频域优化和抽样比例扩大带来的 clean performance 提升。

Table 2: 主要 clean 结果对比。

Run	Feature	Binary F1	Attr. F1	Avg. F1
gray full baseline	FFT/DCT	0.8997	0.9086	0.9042
v2 5% flat	fusion	0.9871	0.9967	0.9919
v2 20% flat	fusion	0.9910	0.9973	0.9942
v2 50% flat	fusion	0.9911	0.9984	0.9948
v2 full best	fusion	0.9913	0.9991	0.9952

multiscale_freq 只强调不同 resize 尺度的功率谱, block_dct 关注局部 8x8 DCT 与 JPEG-like 块结构, residual_freq 关注高通、median 和 Laplacian 残差频谱。第二类是 fusion_freq, 它将颜色、多尺度、块 DCT 和残差频谱合并到同一个特征向量中。

图 2 给出了单一频域与融合频域 profile 的直接对比。在相同 5% 抽样下, color_freq 的双任务平均 F1 约为 0.9887, 是最强的单一频域 profile; block_dct、multiscale_freq 和 residual_freq 单独使用时均明显弱于颜色频谱。融合频域在 5% 抽样下已经达到 0.9919, full scale 后进一步达到 0.9952。这个结果说明单一频域确实含有 AIGC 指纹, 但不同频域统计之

间存在互补性: 颜色频谱提供强判别信号, 多尺度和块 DCT 描述采样/压缩痕迹, 残差频谱补充局部生成噪声差异。

进一步的 feature ablation 结果见图 3。在早期灰度 FFT/DCT baseline 中, fft_radial 与 no_dct 表现最强, 说明径向功率谱已经能捕获大量真假差异; patch_high_freq 单独使用最弱, 说明局部高频变化不足以单独支撑稳定检测。归因任务中也出现类似排序, 表明生成源差异主要分布在全局频谱形态, 而不是单一局部纹理统计。该消融图补充说明: 融合频域不是简单堆叠无关特征, 而是在多个有独立贡献的频谱视角上进行组合。

图 4 展示了从原图到频谱图的可视化示例。真实图像通常具有更接近自然图像统计的径向能量衰减, 而生成图像可能在高频区域、颜色通道或局部残差中出现结构化偏置。虽然单张图不能直接证明模型决策, 但这种可视化能帮助解释为什么浅层频谱统计可以在不理解语义内容的情况下区分 AIGC 图像。

图 5 给出更完整的实验结果总览。与单一频域 profile 相比, 融合频域 profile 不仅提高了二分类, 也显著提高了生成源归因; 与早期灰度 baseline 相比, 第二轮 fusion_freq 路线的提升不是来自单个模型偶然波动, 而是在多个抽样比例和多个任务上同时出现。该图也展示了鲁棒训练分支的定位: mild_aug 和 robust_aug 可作为鲁棒性探索, 但 clean F1 不超过 full fusion 主模型。因此, 最终报告采用 outputs_v2_full_best 作为主




Figure 2: 单一频域 **profile** 与融合频域 **profile** 的实验结果。单一频域包括颜色频谱、多尺度频谱、块 **DCT** 和残差频谱；融合频域将这些信号合并后在 **5%** 与 **full** 设置下都取得更高 **F1**。




Figure 3: 单一频域/单组频谱特征的消融实验结果。左图为真假二分类，右图为生成源归因；径向功率谱和频带斜率贡献稳定，局部 **patch** 高频特征单独使用时较弱。

Table 3: 单一频域 **profile** 与融合频域 **profile** 的代表性结果。

Profile	Binary F1	Attr. F1	Avg. F1
color_freq 5%	0.9833	0.9942	0.9887
block_dct 5%	0.9362	0.9766	0.9564
multiscale 5%	0.9204	0.9007	0.9105
residual 5%	0.9088	0.8951	0.9019
fusion 5%	0.9871	0.9967	0.9919
fusion full	0.9913	0.9991	0.9952

结果，并将训练增强、stable profile 和 leave-one-generator-out 作为严谨性补充。

表 3 进一步给出关键数值。可以看到，颜色频谱是最强的单一频域 **profile**，但仍低于同样 5% 抽样下的融合频域。多尺度、块 **DCT** 和残差频谱单独使用时不一定最强，但它们提供了与颜色频谱不同的统计视角，因此在融合后能提高整体稳定性。图 6 则展示了参数和特征 **profile** 的筛选过程：wide LightGBM

在增强频谱配置中表现最好，也解释了为什么最终主路线固定为 **fusion_freq + wide**。

5.3 Feature Importance and Errors

最终 **full** 模型在 48000 张二分类 **validation** 图像中误判 420 张，在 24000 张归因 **validation** 图像中误判 22 张。二分类错误更多来自 **ADM** 与 **VQDM** 的 **AI** 图像被判为 **nature**；归因错误主要集中在 **ADM** 与 **VQDM** 之间。这说明模型的主要难点不是 **BigGAN** 或 **GLIDE**，而是频谱统计更相近的生成源对。

5.4 Robustness and Generalization

鲁棒性实验直接加载 **outputs_v2_full_best** 的最佳模型，不重新训练。表 4 显示：fusion_freq 在 **clean** 子集上接近满分，但 **JPEG**、**resize** 和 **Gaussian noise** 会显著改变高频与颜色频谱统计，从而造成预测分布偏移。旧灰度 **baseline** 的 **clean** 分数较低，但在部分 **JPEG/noise** 场景更稳，说明 **clean** 性能和 **degraded** 稳定性之间存在取舍。




Figure 4: 真实图像与不同生成源图像的频谱示例。该图用于说明频域指纹来自功率谱分布、频带能量和高频残差差异，而不是来自图像语义内容。




Figure 5: 单一频域、融合频域、不同抽样比例和增强训练分支的整体 **macro-F1** 对比。该图用于补充说明最终主模型选择来自系统实验，而不是只根据单次运行决定。

进一步的 4-generator 扩展实验显示，`stable_freq` 的二分类 `clean F1` 只有 0.8903，但 `degraded` 平均 `F1` 达到 0.6493；`fusion_freq full best` 的二分类 `clean F1` 为 0.9908，但 `degraded` 平均 `F1` 为 0.5717。鲁棒训练分支 `robust_aug` 在归因 `degraded` 平均 `F1` 上提升到 0.6347，但 `clean F1` 低于主模型，因此仅作为 `tradeoff` 分析。

留一生成器泛化实验只用三个生成源训练二分类器，并在被留出的生成源上测试。结果显示 `held-out GLIDE` 的 `macro-F1` 为

0.8877，BigGAN 为 0.7120，ADM 为 0.5696，VQDM 仅为 0.4386。这说明模型确实学习到部分通用 AIGC 指纹，但也明显依赖已见生成器的特定频谱签名。

5.5 Confidence and Rejection

置信度分析导出预测概率、margin 与 entropy，并计算 `coverage-accuracy` 曲线。二分类任务中 BigGAN 的准确率最高，为 0.9953，ADM 与 VQDM 的平均置信度较低；归因任务中 ADM 的准确




Figure 6: 特征 profile 搜索与 LightGBM 参数调优结果。左图展示增强频域特征在不同 LightGBM profile 下的表现，右图展示二分类任务中的 LightGBM 调参对比。




Figure 7: 最终 full 模型在生成源归因任务上的混淆矩阵。

Figure 8: 二分类任务中的 Top-20 频域特征重要性。

Table 4: 20% validation 上的鲁棒性诊断 macro-F1。

Setting	Binary	Attribution
clean	0.9908	0.9992
JPEG 95	0.6607	0.2952
JPEG 50	0.5666	0.2526
resize 0.5	0.3671	0.1551
resize 1.5	0.8136	0.6282
noise 2	0.7481	0.1887
noise 10	0.3377	0.1000

率最低，为 0.9973。这与错误分析一致：ADM/VQDM 是最主要的系统性混淆来源。拒识曲线表明，若允许模型在低置信度样本上输出“不确定”，高覆盖率下仍能保留较高准确率，因此 confidence 可以作为实际部署时的风险控制信号。




Figure 9: 当前 fusion_freq 最佳模型与旧灰度 baseline 的 degraded validation 对照。

ean vs degraded tradeoff / 取舍: AI vs Nature




Figure 10: 左: clean 与 degraded 平均 F1 的取舍; 右: leave-one-generator-out 泛化结果。




Figure 11: 二分类任务的 coverage-accuracy 曲线与置信度分布。

6 Discussion

实验结果显示，AIGC 图像与真实图像在频率域中存在强可分模式。尤其是颜色频谱、多尺度功率谱和残差频谱，使浅层模型在四生成源 `clean validation` 中接近饱和。由于模型特征具有明确物理含义，`feature importance`、混淆矩阵和频谱示例可以解释模型关注的频段和通道。

局限性同样明确。第一，本文只使用 `GenImage` 四个生成源，不声明完整 `GenImage benchmark`。第二，模型是浅层频域检测器，不与大规模深度检测器竞争 SOTA。第三，`degraded evaluation` 表明强 JPEG、缩放和噪声会破坏当前最有效的高频/颜色指纹。如果后续目标是部署到真实社交媒体图像，应进一步研究训练时扰动增强、测试时增强、低中频稳健特征融合或跨生成器域泛化。

7 Conclusion

本文将 AIGC 图像检测转化为可解释的频域统计挖掘问题。最终 `fusion_freq full` 模型在 `clean validation` 上达到二分类 `macro-F1 0.9913` 和归因 `macro-F1 0.9991`，显著超过早期灰度 FFT/DCT baseline。扩展实验进一步指出，`clean` 性能、鲁棒性与跨生成器泛化之间存在明显权衡：频谱融合特征可以大幅提升检测能力，但对后处理扰动敏感。该结论为课程项目提供了检测、归因、解释、鲁棒性诊断和可信度分析的完整闭环。

References

- [1] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. 2017. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In *Advances in Neural Information Processing Systems*.
- [2] Alan V. Oppenheim, Ronald W. Schaffer, and John R. Buck. 1999. *Discrete-Time Signal Processing*. Prentice Hall.
- [3] Mingjian Zhu, Hanting Chen, Qiangyu Yan, Xudong Huang, Guanyu Lin, Wei Li, Zhijun Tu, Hailin Hu, Jie Hu, and Yunhe Wang. 2023. GenImage: A Million-Scale Benchmark for Detecting AI-Generated Image. arXiv:2306.08571 [cs.CV]