

# AIGC 图像的频谱指纹挖掘与伪造检测

Liu Yannan

Southern University of Science and Technology  
Shenzhen, China  
12311122@mail.sustech.edu.cn

Hu Haozhan

Southern University of Science and Technology  
Shenzhen, China  
12310617@mail.sustech.edu.cn

Li Chenyu

Southern University of Science and Technology  
Shenzhen, China  
12312922@mail.sustech.edu.cn

Guo Yaoyuan

Southern University of Science and Technology  
Shenzhen, China  
12312902@mail.sustech.edu.cn

## Abstract

本文面向课程第五题，研究 AIGC 图像在频率域中的可检测指纹。我们使用 GenImage 中 ADM、BigGAN、VQDM 和 GLIDE 四个生成源，构建两个任务：AI/真实图像二分类，以及 AI 图像生成源归因。方法不依赖 CNN 或 Vision Transformer，而是提取 FFT、DCT、颜色频谱、多尺度频谱、块 DCT 与残差频谱统计，并使用 LightGBM 完成浅层可解释建模。最终主模型为 fusion\_freq + flat LightGBM + wide profile，在 full 训练比例下达到二分类 macro-F1 0.9913、AUC 0.9996，归因 macro-F1 0.9991，双任务平均 macro-F1 0.9952。进一步实验表明：频谱融合特征在 clean validation 上极强，但在 JPEG、缩放和高斯噪声等 degraded 场景下明显退化；跨生成器留一测试也显示模型仍会学习到特定生成器的指纹。该结果说明频谱指纹能够有效检测 AIGC 图像，同时鲁棒性与跨生成器泛化仍是关键限制。

## 1 Introduction

扩散模型和 GAN 生成图像的视觉质量持续提升，单靠肉眼已经难以稳定判断图像来源。课程题目要求从像素空间转向频率空间，挖掘人眼不可见但可统计建模的 AIGC 数字指纹。本文因此不把重点放在语义内容识别，而是研究生成过程、上采样链路、压缩后处理和噪声分布可能残留在频谱中的结构化痕迹。

本文围绕三个问题展开：RQ1，FFT/DCT 等频谱统计能否区分 AI 图像与真实图像；RQ2，频谱特征能否识别生成源；RQ3，JPEG、缩放和噪声扰动会怎样破坏或保留频谱指纹。我们的贡献包括：构建四生成源 GenImage 频谱检测流程；比较 baseline、调参、scale-up 和频域增强路线；加入跨生成器泛化、鲁棒性诊断、置信度拒识和错误模式分析；最终形成一个轻量、可解释、可复现的 AIGC 检测闭环。

## 2 Dataset and Protocol

本文使用 GenImage 数据集 [3] 中四个生成源子集：ADM、BigGAN、VQDM 和 GLIDE。数据根目录在代码中通过 --dataset-root 或环境变量 GENIMAGE\_DATA\_ROOT 指定，提交材料中统一记为 PATH\_TO\_GenImage\_data。每个生成源都包含 train/ai、train/nature、val/ai 和 val/nature。实验中 train 用于训练，val 作为测试集。

二分类任务合并四个生成源下的 AI 与 nature 图像，标签为 ai 和 nature。归因任务只使用 AI 图像，标签为 ADM、BigGAN、VQDM 和 GLIDE。抽样实验均使用分层采样和固定 seed；最终主结果使用 full 训练比例。鲁棒性评估不参与训练，只在同一个 20% validation 子集上施加 JPEG、resize 和 Gaussian noise。

Table 1: GenImage 四个生成源的本地数据规模。

| Generator | Train AI | Train Nature | Val AI | Val Nature |
|-----------|----------|--------------|--------|------------|
| ADM       | 162000   | 157453       | 6000   | 6000       |
| BigGAN    | 162000   | 162000       | 6000   | 6000       |
| VQDM      | 162000   | 162000       | 6000   | 6000       |
| GLIDE     | 162000   | 162000       | 6000   | 6000       |

## 3 Method

基础流程首先将图像 resize 到  $256 \times 256$ ，对灰度图去均值并施加 Hann 窗，然后计算二维 FFT 功率谱：

$$P(u, v) = \log(1 + |\mathcal{F}(I)(u, v)|^2).$$

baseline 特征包括 FFT 径向功率谱、角向能量、低/中/高频能量比例、频谱斜率、高频残差统计、patch 级高频变化和 DCT 径向谱。为进一步提分，本文实现 fusion\_freq profile：在 RGB 与 YCbCr 通道上提取颜色频谱，在 128/256/384 三个尺度上提取多尺度频谱，加入 8x8 block-DCT AC 能量和块边界统计，并对高通、median 与 Laplacian 残差再做频谱统计。所有特征都对明确的信号处理统计，不依赖语义表征。

这些频域特征的设计目标不是简单增加维度，而是覆盖生成图像可能留下指纹的几个互补来源。第一，径向功率谱和频谱斜率描述自然图像常见的能量衰减规律。如果生成模型的上采样、去噪或后处理链路改变了高低频能量分配，径向统计会直接反映这种偏移。第二，角向能量与块 DCT 统计用于捕获方向性纹理和局部周期结构。真实相机图像中的纹理方向通常与场景内容相关，而生成模型可能产生更规则的方向性伪影；JPEG-like 块边界也会改变局部 DCT AC 能量。第三，颜色频谱把灰度空间中被平均掉的通道差异重新引入模型。扩散模型和 GAN 在 RGB 或 YCbCr 通道上可能具有不同的高频噪声分布，因此颜色频域特征在第二轮实验中贡献最大。第四，残差频谱弱化低频语义轮廓，突出高通、median 和 Laplacian 残差中的细粒度噪声。该组特征有助于区分自然图像的传感器噪声与生成图像的合成残差。

本文同时保留了“单一频域”和“融合频域”两套实验口径。单一频域实验用于回答某一类信号是否独立有效，例如只用颜色频谱或只用 block-DCT 是否已经能完成检测；融合频域实验则用于回答这些信号是否互补。这样做可以避免把提升简单归因于特征数量增加。若某个单一 profile 已经接近融合 profile，则说明主要信息集中在该频域；若多个单一 profile 都弱于融合 profile，则说明不同频域捕获了不同类型的生成痕迹。后续结果显示颜色频谱最强，但融合频域仍进一步提升，因此最终方法采用 fusion\_freq 作为主路线。

监督模型以 LightGBM [1] 为主, RandomForest 和 LogisticRegression 作为早期 baseline。最终路线使用 flat LightGBM、多分类归因、wide 参数 profile 和二分类阈值校准。LightGBM 训练优先使用 GPU; 若 GPU 在复杂多分类训练中失败, 代码自动 fallback 到 CPU。频谱特征提取主要依赖 CPU 多进程和 feature cache。信号处理背景参考 Oppenheim 等人的经典教材 [2]。

选择 LightGBM 的原因有三点。首先, 它能处理数百到上千维手工统计特征, 并给出稳定的 feature importance, 因此适合课程要求中的“可解释模型”。其次, 它比深度 CNN/ViT 更容易复现, 训练结果主要受特征和抽样策略影响, 而不是受大量超参数或预训练权重影响。第三, 树模型可以较自然地建模频带比值、颜色通道能量和残差统计之间的非线性组合。为了控制过拟合, 本文没有把所有中间实验都作为最终结论, 而是使用 5% 调参、10% 验证、20/50/full scale-up 的逐级流程来确认提升是否稳定。

## 4 Experiments

实验分为五层。第一层使用 1%、5% 和 10% 抽样验证原始 FFT/DCT baseline, 并完成 LightGBM 调参。第二层进行 20%、50% 和 full scale-up, 确认样本量扩大能稳定提升 clean performance。第三层进行频域增强, 比较 color\_freq、multiscale\_freq、block\_dct、residual\_freq 和 fusion\_freq。第四层固定最终模型, 在 validation 图像上施加 JPEG、resize 和 Gaussian noise, 诊断后处理扰动下的失效模式。第五层扩展分析跨生成器泛化、鲁棒训练、稳健频谱 profile 和置信度拒识。

所有主要结果通过 metrics\_summary.json、model\_comparison.csv、混淆矩阵、feature importance、robustness CSV 和 confidence CSV 自动汇总到 report/tables 与 report/figures。Notebook 只读取这些资产, 不重新执行大规模训练。

工程实现上, 实验被拆分为可中断、可恢复的输出目录。每个任务目录都保存模型比较表、最佳模型、混淆矩阵、错误样本和配置文件; 特征缓存单独存放, 避免重复扫描完整图像集。这样做的意义在于: 一方面, full-scale 频谱特征提取耗时较长, 缓存能保证后续调参、鲁棒性评估和 Notebook 展示不必重复计算; 另一方面, 不同阶段的输出目录天然形成实验记录, 报告中的每张图都可以追溯到具体 CSV 或 JSON。对于队友分机器运行得到的结果, 本文也只要把最终 CSV/PNG 资产纳入报告, 不把数据集、缓存和大模型输出提交到仓库。

评价指标以 macro-F1 为主, 因为二分类与归因任务都需要避免被某个类别的大样本量掩盖。二分类同时记录 AUC, 用于观察阈值之外的排序能力; 归因任务主要关注混淆矩阵, 尤其是 ADM 与 VQDM 之间的系统性错误。鲁棒性部分不只看 clean 分数, 还统计每种扰动级别下的 macro-F1、预测分布和 degraded 平均 F1。跨生成器泛化实验只训练二分类器, 因为它更直接回答“是否学到通用 AIGC 指纹”, 而不是在未见生成源标签不存在时强行做归因。

## 5 Results and Analysis

### 5.1 Clean Performance

表 2 汇总了从旧灰度 baseline 到第二轮频域融合优化的关键结果。第一轮 full baseline 的双任务平均 macro-F1 为 0.9042; 引入 fusion\_freq 后, 5% 抽样已经达到 0.9919, full 训练比例进一步达到 0.9952。最终主结果固定为 outputs\_v2\_full\_best, 不把后续鲁棒训练分支替代为主模型。

Table 2: 主要 clean 结果对比。

| Run                | Feature | Binary F1     | Attr. F1      | Avg. F1       |
|--------------------|---------|---------------|---------------|---------------|
| gray full baseline | FFT/DCT | 0.8997        | 0.9086        | 0.9042        |
| v2 5% flat         | fusion  | 0.9871        | 0.9967        | 0.9919        |
| v2 20% flat        | fusion  | 0.9910        | 0.9973        | 0.9942        |
| v2 50% flat        | fusion  | 0.9911        | 0.9984        | 0.9948        |
| v2 full best       | fusion  | <b>0.9913</b> | <b>0.9991</b> | <b>0.9952</b> |




Figure 1: 第二轮频域优化和抽样比例扩大带来的 clean performance 提升。

### 5.2 Single-Domain and Fused Frequency Results

为了区分“单一频域特征有效”与“融合频域特征更强”这两个结论, 本文将第二轮特征实验拆成两类。第一类是单一或局部频域 profile: color\_freq 只强调 RGB/YCbCr 颜色通道频谱, multiscale\_freq 只强调不同 resize 尺度的功率谱, block\_dct 关注局部 8x8 DCT 与 JPEG-like 块结构, residual\_freq 关注高通、median 和 Laplacian 残差频谱。第二类是 fusion\_freq, 它将颜色、多尺度、块 DCT 和残差频谱合并到同一个特征向量中。

图 2 给出了单一频域与融合频域 profile 的直接对比。在相同 5% 抽样下, color\_freq 的双任务平均 F1 约为 0.9887, 是最强的单一频域 profile; block\_dct、multiscale\_freq 和 residual\_freq 单独使用时均明显弱于颜色频谱。融合频域在 5% 抽样下已经达到 0.9919, full scale 后进一步达到 0.9952。这个结果说明单一频域确实含有 AIGC 指纹, 但不同频域统计之间存在互补性: 颜色频谱提供强判别信号, 多尺度和块 DCT 描述采样/压缩痕迹, 残差频谱补充局部生成噪声差异。






Figure 2: 单一频域 profile 与融合频域 profile 的实验结果。单一频域包括颜色频谱、多尺度频谱、块 DCT 和残差频谱; 融合频域将这些信号合并后在 5% 与 full 设置下都取得更高 F1。

进一步的 feature ablation 结果见图 3。在早期灰度 FFT/DCT baseline 中, `fft_radial` 与 `no_dct` 表现最强, 说明径向功率谱已经能捕获大量真假差异; `patch_high_freq` 单独使用最弱, 说明局部高频变化不足以单独支撑稳定检测。归因任务中也出现类似排序, 表明生成源差异主要分布在全局频谱形态, 而不是单一局部纹理统计。该消融图补充说明: 融合频域不是简单堆叠无关特征, 而是在多个有独立贡献的频谱视角上进行组合。




**Figure 3:** 单一频域/单组频谱特征的消融实验结果。左图为真假二分类, 右图为生成源归因; 径向功率谱和频带斜率贡献稳定, 局部 `patch` 高频特征单独使用时较弱。

图 4 展示了从原图到频谱图的可视化示例。真实图像通常具有更接近自然图像统计的径向能量衰减, 而生成图像可能在高频区域、颜色通道或局部残差中出现结构化偏置。虽然单张图不能直接证明模型决策, 但这种可视化能帮助解释为什么浅层频谱统计可以在不理解语义内容的情况下区分 AIGC 图像。



**Figure 4:** 真实图像与不同生成源图像的频谱示例。该图用于说明频域指纹来自功率谱分布、频带能量和高频残差差异, 而不是来自图像语义内容。

图 5 给出更完整的实验结果总览。与单一频域 profile 相比, 融合频域 profile 不仅提高了二分类, 也显著提高了生成源归因; 与早期灰度 baseline 相比, 第二轮 `fusion_freq` 路线的提升不是来自单个模型偶然波动, 而是在多个抽样比例和多个任务上同时出现。该图也展示了鲁棒训练分支的定位: `mild_aug` 和 `robust_aug` 可作为鲁棒性探索, 但 `clean F1` 不超过 `full fusion` 主模型。因此, 最终报告采用 `outputs_v2_full_best` 作为主结果, 并将训练增强、stable profile 和 leave-one-generator-out 作为严谨性补充。




**Figure 5:** 单一频域、融合频域、不同抽样比例和增强训练分支的整体 **macro-F1** 对比。该图用于补充说明最终主模型选择来自系统实验, 而不是只根据单次运行决定。

**Table 3:** 单一频域 profile 与融合频域 profile 的代表性结果。

| Profile       | Binary F1     | Attr. F1      | Avg. F1       |
|---------------|---------------|---------------|---------------|
| color_freq 5% | 0.9833        | 0.9942        | 0.9887        |
| block_dct 5%  | 0.9362        | 0.9766        | 0.9564        |
| multiscale 5% | 0.9204        | 0.9007        | 0.9105        |
| residual 5%   | 0.9088        | 0.8951        | 0.9019        |
| fusion 5%     | 0.9871        | 0.9967        | 0.9919        |
| fusion full   | <b>0.9913</b> | <b>0.9991</b> | <b>0.9952</b> |

表 3 进一步给出关键数值。可以看到, 颜色频谱是最强的单一频域 profile, 但仍低于同样 5% 抽样下的融合频域。多尺度、块 DCT 和残差频谱单独使用时不一定最强, 但它们提供了与颜色频谱不同的统计视角, 因此在融合后能提高整体稳定性。图 6 则展示了参数和特征 profile 的筛选过程: `wide LightGBM` 在增强频域配置中表现最好, 也解释了为什么最终主路线固定为 `fusion_freq + wide`。



**Figure 6:** 特征 profile 搜索与 `LightGBM` 参数调优结果。左图展示增强频域特征在不同 `LightGBM` profile 下的表现, 右图展示二分类任务中的 `LightGBM` 调参对比。

### 5.3 Feature Importance and Errors

最终 `full` 模型在 48000 张二分类 validation 图像中误判 420 张, 在 24000 张归因 validation 图像中误判 22 张。二分类错误更多来自 `ADM` 与 `VQDM` 的 AI 图像被判为 `nature`; 归因错误主要集中在 `ADM` 与 `VQDM` 之间。这说明模型的主要难点不是 `BigGAN` 或 `GLIDE`, 而是频谱统计更相近的生成源对。




Figure 7: 最终 full 模型在生成源归因任务上的混淆矩阵。




Figure 8: 二分类任务中的 Top-20 频域特征重要性。

特征重要性进一步支持了“颜色频谱 + 局部 DCT + 残差统计”共同起作用的结论。Top feature 中既包含 YCbCr 通道的高频标准差、band energy 和径向 DCT 统计，也包含 block-DCT 中高频 AC 能量和 residual median 高频统计。这说明模型并不是只依赖单个阈值或单个频段，而是在多个互补频域视角上形成判别边界。对于二分类，颜色通道高频和中高频能量最有用，符合生成图像在颜色噪声、去噪残差和上采样纹理上存在系统偏差的假设。对于归因任务，特征重要性更偏向生成器特定的频谱形态，例如 ADM/VQDM 的残差频谱差异、BigGAN 的局部纹理周期性和 GLIDE 的频带能量分布。

错误分析也说明模型的失败不是随机噪声。二分类中的误判主要出现在 ADM 与 VQDM：部分 AI 图像被判成 nature，说明这些生成源在某些样本上的频谱更接近自然图像统计；少量 nature 被判成 AI，通常具有强纹理、重复边缘或压缩伪影，这些模式会被浅层频谱模型误认为生成痕迹。归因任务中，BigGAN 和 GLIDE 几乎不混淆，说明它们的频谱签名较稳定；ADM 与 VQDM 的混淆更多，说明这两个扩散/量化扩散相关生成源在全局功率谱和残差噪声上更相近。因此，后续提升归因任务的关键不是继续扩大已有样本，而是设计专门区分 ADM/VQDM 的专家特征或 pairwise classifier。

从可解释性角度看，错误样本列表比单一准确率更重要。项目导出的 prediction\_errors.csv 记录了路径、真实标签、预测标签和模型置信度，可用于检查高置信度错误是否集中在特定生成器或特定图像类型。如果高置信度错误集中在纹理复杂的 nature 图像，说明模型把自然纹理误认为生成伪影；如果集中在某个 AI 生成源，说明该生成源的频谱分布与训练中其它源不一致。这样的分析能把“模型错了多少”进一步转化为“模型为什么错”，也使报告中的可解释性不只停留在 feature importance 条形图。

## 5.4 Robustness and Generalization

鲁棒性实验直接加载 outputs\_v2\_full\_best 的最佳模型，不重新训练。表 4 显示：fusion\_freq 在 clean 子集上接近满分，但 JPEG、resize 和 Gaussian noise 会显著改变高频与颜色频谱统计，从而造成预测分布偏移。旧灰度 baseline 的 clean 分数较低，但在部分 JPEG/noise 场景更稳，说明 clean 性能和 degraded 稳定性之间存在取舍。

Table 4: 20% validation 上的鲁棒性诊断 macro-F1。

| Setting    | Binary | Attribution |
|------------|--------|-------------|
| clean      | 0.9908 | 0.9992      |
| JPEG 95    | 0.6607 | 0.2952      |
| JPEG 50    | 0.5666 | 0.2526      |
| resize 0.5 | 0.3671 | 0.1551      |
| resize 1.5 | 0.8136 | 0.6282      |
| noise 2    | 0.7481 | 0.1887      |
| noise 10   | 0.3377 | 0.1000      |




Figure 9: 当前 fusion\_freq 最佳模型与旧灰度 baseline 的 degraded validation 对照。

鲁棒性结果说明，clean performance 不能直接等价于真实部署场景中的稳定性。JPEG 压缩会量化局部 DCT 系数并抑制高频细节，恰好破坏 fusion\_freq 中贡献较大的颜色高频和 block-DCT 统计；因此 JPEG 95 已经使二分类 F1 从 0.9908 降到 0.6607，JPEG 50 下进一步下降。缩放扰动的影响具有方向



性：resize 0.5 会丢失细节并重采样高频，二分类 F1 降到 0.3671；resize 1.5 虽然也改变频谱，但保留了更多原始结构，因此二分类 F1 仍有 0.8136。高斯噪声则直接向高频区域注入随机能量，使模型学习到的“生成残差”与外加噪声混合，导致强噪声下性能明显下降。

归因任务在 degraded 场景下退化更严重，这与任务定义有关。二分类只需要判断“是否 AI”，仍可能利用部分残留的通用频谱偏差；归因任务需要区分 ADM、BigGAN、VQDM 和 GLIDE 的细粒度签名，一旦 JPEG、resize 或 noise 抹平生成器间差异，类别边界就会快速变得不稳定。这个现象也是本文的重要负面结果：频域融合可以显著提升 clean 归因，但它对后处理更敏感。报告中因此不把鲁棒性实验写成“已解决”，而是作为失效模式诊断。

旧灰度 baseline 在 clean 分数上远低于 fusion\_freq，但在部分 degraded 条件下并没有同等幅度崩溃。这说明较简单的低维灰度频谱特征可能更少依赖颜色高频细节，因而在强压缩或噪声下有时更稳。后续如果目标从课程实验转向真实平台部署，合理路线不是继续单纯提高 clean F1，而是组合三类策略：训练时加入压缩、缩放和噪声增强；测试时对多个扰动版本做特征平均或投票；在特征层降低对极高频率统计的依赖，增加更稳健的低/中频和 DCT 结构统计。

进一步的 4-generator 扩展实验显示，stable\_freq 的二分类 clean F1 只有 0.8903，但 degraded 平均 F1 达到 0.6493；fusion\_freq full best 的二分类 clean F1 为 0.9908，但 degraded 平均 F1 为 0.5717。鲁棒训练分支 robust\_aug 在归因 degraded 平均 F1 上提升到 0.6347，但 clean F1 低于主模型，因此仅作为 tradeoff 分析。




Figure 10: 左：clean 与 degraded 平均 F1 的取舍；右：leave-one-generator-out 泛化结果。

留一生成器泛化实验只用三个生成源训练二分类器，并在被留下的生成源上测试。结果显示 held-out GLIDE 的 macro-F1 为 0.8877，BigGAN 为 0.7120，ADM 为 0.5696，VQDM 仅为 0.4386。这说明模型确实学习到部分通用 AIGC 指纹，但也明显依赖已见生成器的特定频谱签名。

留一实验的排序也提供了对生成源差异的解释。GLIDE 被留出时仍能取得较高 F1，说明它与其他生成源共享的频谱偏差较多；VQDM 被留出时 F1 最低，说明它的频谱统计与训练中可见生成源差异较大，或更容易与真实图像统计接近。这个结果提醒我们，四生成源 clean 测试上的高分并不能自动推广到未见生成器。若要扩展为更严格的 benchmark，应补齐 Midjourney、Wukong、Stable Diffusion V1.4/V1.5 等生成源，并把“训练可见生成器、测试未见生成器”作为主要评价协议之一。

## 5.5 Confidence and Rejection

置信度分析导出预测概率、margin 与 entropy，并计算 coverage-accuracy 曲线。二分类任务中 BigGAN 的准确率最高，为 0.9953，ADM 与 VQDM 的平均置信度较低；归因任务中 ADM 的准确率最低，为 0.9973。这与错误分析一致：ADM/VQDM 是最主要的系统性混淆来源。拒识曲线表明，若允许模型在低置信度样本上输出“不确定”，高覆盖率下仍能保留较高准确率，因此 confidence 可以作为实际部署时的风险控制信号。

置信度分析的作用不是继续提高分数，而是为模型可信度提供可操作的解释。在实际应用中，检测器不一定必须对每张图片给出二元结论；当 margin 较小或 entropy 较高时，可以把样本交给人工复核或更强的深度模型。本文导出的 low-confidence list 和 high-confidence wrong list 可以帮助定位两类风险：前者代表模型本身不确定的边界样本，后者代表模型非常自信但判断错误的系统性盲区。对于课程项目，这部分补充了从“模型准确”到“模型何时不可靠”的分析链条。




Figure 11: 二分类任务的 coverage-accuracy 曲线与置信度分布。

## 6 Discussion

实验结果显示，AIGC 图像与真实图像在频率域中存在强可分模式。尤其是颜色频谱、多尺度功率谱和残差频谱，使浅层模型在四生成源 clean validation 中接近饱和。由于模型特征具有明确物理含义，feature importance、混淆矩阵和频谱示例可以解释模型关注的频段和通道。

从课程要求看，本项目覆盖了“检测、归因、鲁棒性和解释”四个核心面。检测层面，二分类任务验证频谱统计能否区分 AI 与真实图像；归因层面，四分类任务检验不同生成算法是否具有独特频谱签名；鲁棒性层面，JPEG、resize 和 noise 说明哪些指纹容易被后处理破坏；解释层面，feature importance、频谱示例和错误分析给出模型为什么有效、又在哪些样本上失败。与端到端深度检测器相比，这种流程的优势是可拆解：每个分数都能回溯到具体频段、通道或残差统计，而不是只给出一个黑盒预测。

但局限性同样明确。第一，本文只使用 GenImage 四个生成源，不声明完整 GenImage benchmark。四个生成源足以支撑课程第五题的主要目标，但不能代表全部生成模型，尤其不能覆盖最新文生图系统和真实社交媒体压缩链路。第二，模型是浅层频域检测器，不与大规模深度检测器竞争 SOTA。它牺牲了语义理解和复杂空间模式建模能力，换取轻量、可解释和易复现。第三，degraded evaluation 表明强 JPEG、缩放和噪声会破坏当前最有效的高频/颜色指纹，说明频谱检测器可能被简单后处理削弱。第四，留一生成器实验显示模型仍依赖已见生成器的特定签名，跨生成器泛化没有完全解决。

因此后续提升应从三个方向展开。第一，数据层面补齐 GenImage 的其余生成源，并增加真实平台下载图像，构造更

接近部署场景的压缩与缩放分布。第二，特征层面研究稳健频谱表示，例如低/中频 band ratio、JPEG 不变量、跨尺度一致性和颜色通道归一化，减少对极高频细节的依赖。第三，模型层面可以在保持可解释性的前提下做集成：用 fusion\_freq 负责 clean 高分，用 stable\_freq 或灰度频谱负责 degraded 稳定性，再通过置信度或校准模型选择输出。若允许加入深度模型，也应把 CNN/ViT 作为对照，而不是替代本文的频域解释主线。

**Reproducibility and submission.** 为了保证课程提交材料可以复查，本文把“大计算”和“展示资产”拆开处理。完整训练输出、特征缓存和 GenImage 数据集不进入 Git 仓库；仓库中保留的是代码、报告源码、Notebook、关键 CSV 表格和重新绘制后的 PNG 图。Notebook 的作用不是重新训练 full 模型，而是读取已有 report/tables 与 report/figures，展示数据统计、主结果、鲁棒性曲线、泛化结果和置信度分析。这样可以避免提交文件过大，同时保证 Notebook 中的数值和报告中的图表一致。

复现实验时，最小流程是先准备四个生成源的 train/ai、train/nature、val/ai 和 val/nature，再运行特征提取和 LightGBM 训练脚本。若只想验证结论而不重新训练，可以直接运行报告资产脚本和提交检查脚本；它们会读取已经完成的输出目录，生成 experiment\_summary.csv、robustness\_comparison.csv、混淆矩阵、feature importance 和 confidence 图。该设计使项目既能展示完整实验过程，也能在提交前快速检查 PDF、Notebook、数据路径和结果文件是否一致。

本项目的工程经验也值得记录。频谱特征提取主要消耗 CPU 和磁盘 I/O，适合多进程并行；LightGBM 训练在二分类或中等规模任务中可以使用 GPU，但复杂多分类在某些环境下可能触发 GPU split 错误，因此代码加入 CPU fallback。大规模实验应优先复用 feature cache，而不是重复读取图像。鲁棒性评估不需要重新训练模型，只需要对 validation 图像施加扰动并重新提取特征，因此更适合 CPU 资源充足的机器。上述经验帮助我们多天实验拆分给不同机器运行，并把结果重新汇总到统一报告中。

从最终提交角度看，本文的主结果和补充结果有明确边界。主结果只采用 outputs\_v2\_full\_best，因为它在 clean 二分类和归因任务上都达到最高或接近最高的 macro-F1；鲁棒训练、stable\_freq 和留一生成器实验不替代主模型，而是用于解释 tradeoff。这样写法避免了把所有实验都包装成“提升”，也避免在报告中夸大鲁棒性。更准确的结论是：频谱融合能把 clean performance 推到很高，但稳定部署还需要针对后处理扰动和未见生成器单独优化。

**Threats to validity.** 还有一些潜在威胁需要在提交前明确。第一，本文把 GenImage 的 val split 当作测试集使用，这符合当前代码结构，但不是严格意义上的独立外部测试集；因此结论应解释为“四生成源 GenImage 子集上的实验结果”，而不是对所有 AIGC 图像的普遍声明。第二，真实图像与 AI 图像可能存在采集链路、压缩质量和分辨率分布差异，频谱模型可能同时学习到生成器指纹和数据处理痕迹。本文通过鲁棒性实验暴露了这种风险，但还没有完全消除它。第三，模型选择主要依据 macro-F1，虽然该指标适合类别均衡的课程实验，但实际部署还需要考虑误报成本、漏报成本和人工复核成本。

另一个威胁来自解释方法本身。LightGBM feature importance 能说明哪些频域统计被树模型频繁使用，但它不等同于因果解释；某个特征重要，可能是因为它本身含有生成指纹，也可能是因为它与其它真正原因高度相关。因此，本文同时使用 feature importance、混淆矩阵、频谱示例和错误样本列表交叉

解释，避免只凭单一条形图下结论。对于未来工作，更严格的做法是进行 controlled perturbation：只改变某个频带、颜色通道或压缩强度，观察模型输出是否按预期变化。

最后，本文的浅层频域路线适合作为可解释 detector 或深度模型前置筛查器，而不一定适合作为唯一判定工具。频谱指纹对生成过程非常敏感，这带来 clean 场景下的高分，也带来后处理下的脆弱性。实际系统可以把本方法输出的概率、置信度和拒识标记作为风险信号，再结合图像元数据、传播链路或深度语义检测器。这样既保留频域方法的透明性，也能缓解单一特征族被规避的问题。

**How to read the results.** 在展示和报告中，最需要强调的不是“模型分数接近 1”，而是分数背后的条件。主模型在同分布 clean validation 上表现很强，说明频谱统计确实能捕获四个已见生成源的数字指纹；但鲁棒性和留一实验同时说明，这些指纹会被后处理扰动削弱，也不一定完整迁移到未见生成器。因此，本项目更合理的定位是一个可解释的频谱检测研究，而不是一个已经可直接上线的通用检测器。这样的解读能同时体现方法有效性和研究边界。

从课程评分角度看，本文的创新性主要体现在两点。第一，实验没有停留在“FFT/DCT 加一个分类器”的 baseline，而是逐步加入颜色、多尺度、块 DCT 和残差频谱，并通过单一 profile 对比说明融合的必要性。第二，报告没有只展示最高 clean 分数，而是加入鲁棒性、跨生成器、置信度和错误分析，说明模型何时有效、何时不可靠。工程复杂度则体现在缓存、断点续跑、GPU fallback、多机结果汇总和 Notebook/报告资产一致性检查上。这些内容虽然不是主模型本身，但使项目更完整、更可复现。

Table 5: 最终提交资产及其作用。

| Asset          | Role                                         |
|----------------|----------------------------------------------|
| main.pdf       | ACM sigconf 风格总结报告，记录问题定义、方法、实验和结论。          |
| Notebook       | 展示核心代码流程、已有运行结果和与报告一致的可视化。                   |
| report/tables  | 保存 clean、robustness、confidence 和泛化实验的汇总 CSV。 |
| report/figures | 保存所有报告图片，均由已有实验输出重新绘制。                       |
| Source code    | 保留特征提取、训练、鲁棒性评估和资产生成脚本。                      |

这份资产划分也反映了最终项目的取舍：数据和缓存服务于实验运行，不适合作为提交物；CSV、PNG、Notebook 和 PDF 服务于复核与展示，必须保持一致。换言之，最终交付不是简单把本地目录打包，而是把可复现代码、关键结果和解释材料组织成一套可以被助教快速检查的证据链。

## 7 Conclusion

本文将 AIGC 图像检测转化为可解释的频域统计挖掘问题。最终 fusion\_freq full 模型在 clean validation 上达到二分类 macro-F1 0.9913 和归因 macro-F1 0.9991，显著超过早期灰度 FFT/DCT baseline。扩展实验进一步指出，clean 性能、鲁棒性与跨生成器泛化之间存在明显权衡：频谱融合特征可以大幅提

升检测能力，但对后处理扰动敏感。该结论为课程项目提供了检测、归因、解释、鲁棒性诊断和可信度分析的完整闭环。

更具体地说，本项目得到三点结论。第一，频域统计不是只能做简单真假检测，也可以用于生成源归因；当颜色频谱、多尺度频谱、块 DCT 和残差频谱共同使用时，浅层 LightGBM 已经能在四生成源 **clean validation** 上达到很高性能。第二，单一频域 **profile** 具有解释价值：颜色频谱贡献最大，block-DCT 和残差频谱补充局部压缩/噪声线索，多尺度频谱帮助观察采样尺度变化。第三，鲁棒性实验揭示了高分模型的边界：JPEG、resize 和 Gaussian noise 会改变频谱统计，尤其会削弱归因任务所需的细粒度生成器签名。

因此，本文最终不把该系统包装为通用 AIGC 检测器，而是把它定位为一个频谱指纹挖掘框架。它的价值在于以较低工程成本给出可解释判断，并能通过特征重要性、混淆矩阵、错误样本和 **confidence curve** 说明模型的有效区域与风险区域。若未来继续推进，应优先补充更多生成器和真实平台扰动分布，同时研究稳健频域特征与深度模型对照。这样的延伸能够把课程项目中的可解释实验，进一步发展为面向真实场景的可靠检测方案。

从课程项目的角度看，本文的次要实验并不是附加装饰，而是用来避免单一分数叙事。留一生成器实验检验模型是否依赖某个特定 **generator**；鲁棒性评估检验频谱指纹在后处理下是否仍然稳定；置信度和拒识曲线说明模型在低把握样本上应如何被使用；单一频域与融合频域对比则解释了为什么最终选择 **fusion\_freq**，也解释了它为何在 **degraded** 场景下更容易退化。把这些结果放在主实验之后，可以形成一条较完整的证据链：先证明方法有效，再说明有效性来自哪些频域线索，最后指出这些线索在哪些条件下会失效。

这种组织方式也决定了最终交付的复核路径。读者可以先从 **Notebook** 中查看数据统计和核心图表，再回到报告中理解实验设计与结论；若要复现实验，可以按 **README** 中的命令从小规模 **smoke test** 开始，再逐步扩大到 **full clean** 结果和 20%

**robustness** 诊断。由于所有图表都来自仓库中的 CSV 或已完成输出目录，报告中的图、表和 **Notebook** 的运行结果保持一致。对于一个数据挖掘课程项目而言，这比单纯追求更高 **clean F1** 更重要：它展示了问题定义、特征工程、模型选择、误差分析、鲁棒性诊断和可复现提交之间的完整流程。

若在当前四生成源基础上继续扩展，最直接的路线不是把新增数据简单并入训练集，而是把 Midjourney、Wukong、Stable Diffusion V1.4/V1.5 等生成源作为外部验证或分阶段增量实验。第一步可以保持现有四生成源模型不变，直接测试未见生成器，得到真正的 **cross-generator generalization** 指标；第二步再把新增生成源加入训练，观察二分类与归因任务是否同时受益；第三步比较旧生成器上的性能是否下降，从而判断模型是否出现生成源间的 **tradeoff**。这样的扩展比单纯报告八生成源平均分更有信息量，因为它能区分“数据更多带来的整体提升”和“模型对未见生成器的真实泛化能力”。

最终版本也刻意保留了这些负面发现。报告没有把鲁棒性退化删掉，也没有把旧灰度 **baseline** 的 **degraded** 优势解释成失败；相反，这些现象说明频谱检测器确实依赖图像处理链路中的细节。对于课堂验收而言，这种写法比单纯展示最高 F1 更严谨：它说明模型什么时候可信、什么时候需要人工复核或额外模型辅助。若后续报告篇幅允许，还可以把更多误判频谱图放入附录或 **Notebook**，而正文只保留最能支撑论点的表格和曲线。

## References

- [1] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. 2017. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In *Advances in Neural Information Processing Systems*.
- [2] Alan V. Oppenheim, Ronald W. Schaffer, and John R. Buck. 1999. *Discrete-Time Signal Processing*. Prentice Hall.
- [3] Mingjian Zhu, Hanting Chen, Qiangyu Yan, Xudong Huang, Guanyu Lin, Wei Li, Zhijun Tu, Hailin Hu, Jie Hu, and Yunhe Wang. 2023. GenImage: A Million-Scale Benchmark for Detecting AI-Generated Image. arXiv:2306.08571 [cs.CV]