

AIGC 图像的频谱指纹挖掘与伪造检测

Team members: [fill in]

[fill in]

[fill in], China

[fill in]

Abstract

本文面向课程第五题，研究 AIGC 图像在频率域中的可检测指纹。我们基于 GenImage 的 ADM、BigGAN、VQDM 和 GLIDE 四个生成源构建两个任务：AI/真实图像二分类，以及 AI 图像的生成源归因。方法不引入 CNN 或 Vision Transformer，而是提取 FFT、DCT、颜色频谱、多尺度频谱、块 DCT 与残差频谱统计，并使用 LightGBM 完成浅层可解释建模。最终最佳路线为 fusion_freq + flat LightGBM + wide profile，在 full 训练比例下达到二分类 macro-F1 0.9913、AUC 0.9996，归因 macro-F1 0.9991，双任务平均 macro-F1 0.9952。进一步的 20% degraded validation 表明，该模型在 clean 数据上极强，但在 JPEG、resize 和 Gaussian noise 下明显退化；旧灰度 baseline clean 分数较低，却在部分 JPEG/noise 场景更稳。结果说明频谱指纹能有效检测 AIGC 图像，同时也暴露出高频和颜色频谱特征对后处理扰动的脆弱性。

1 Introduction

扩散模型和 GAN 生成图像的视觉质量持续提升，单靠肉眼已经难以判断图像来源。课程项目第五题关注 AIGC 图像的数据生成机制与伪造检测，因此本文不把重点放在语义识别，而是挖掘生成过程可能残留在频率域中的统计痕迹。上采样、去噪、压缩链路和生成器结构都可能改变功率谱分布、方向性能量、高频残差和局部频率变化，这些模式为轻量检测提供了可解释依据。

本文围绕三个研究问题展开：RQ1，频谱统计能否区分 AI 图像与真实图像；RQ2，频谱特征能否识别生成源；RQ3，JPEG、缩放和噪声扰动会怎样破坏或保留频谱指纹。贡献包括：构建 GenImage 四生成源频域检测流程；比较并调优浅层模型；提出颜色、多尺度、块 DCT 和残差频谱融合特征；补充 clean performance、scale-up、鲁棒性诊断、错误分析和特征重要性解释。

2 Dataset and Protocol

本文使用 GenImage 数据集 [3] 中的四个生成源子集：ADM、BigGAN、VQDM 和 GLIDE。数据根目录为 C:\Users\99303\git\GenImage\data，每个生成源均包含 train/ai、train/nature、val/ai 和 val/nature。实验中 train 用于训练，val 作为测试集。

二分类任务合并四个生成源下的 AI 与 nature 图像，标签为 ai 和 nature。归因任务只使用 AI 图像，标签为 ADM、BigGAN、VQDM 和 GLIDE。所有抽样实验均使用分层采样和固定 seed；最终主结果使用 full 训练比例，鲁棒性诊断使用同一模型在 20% validation 子集上评估。

3 Method

基础特征首先将图像 resize 到 256×256 ，对灰度图去均值并施加 Hann 窗，然后计算二维 FFT 功率谱：

$$P(u, v) = \log(1 + |\mathcal{F}(I)(u, v)|^2).$$

Table 1: GenImage 四个生成源的本地数据规模。

Generator	Train AI	Train Nature	Val AI	Val Nature
ADM	162000	157453	6000	6000
BigGAN	162000	162000	6000	6000
VQDM	162000	162000	6000	6000
GLIDE	162000	162000	6000	6000

baseline 特征包括 FFT 径向功率谱、角向能量、低/中/高频能量比例、频谱斜率、高频残差统计、patch 级高频变化和 DCT 径向谱。为了进一步提分，本文增加 fusion_freq profile：在 RGB 与 YCbCr 通道上提取颜色频谱；在 128、256 和 384 三个尺度上提取多尺度频谱；加入 8x8 block-DCT AC 能量和块边界统计；并对高通、median 与 Laplacian 残差再做频谱统计。这些特征仍对应明确的信号处理统计，不依赖语义表示。

监督模型以 LightGBM [1] 为主，RandomForest 和 LogisticRegression 作为早期 baseline。最终路线使用 flat LightGBM 多分类结构、wide profile 和阈值校准。LightGBM 训练优先使用 GPU；若 GPU 在多分类训练中报错，代码自动 fallback 到 CPU。频谱特征提取主要依赖 CPU 多进程和 feature cache。信号处理背景参考 Oppenheim 等人的经典教材 [2]。

4 Experiments

实验分为四层推进。第一层用 1%、5% 和 10% 抽样验证原始 FFT/DCT baseline，并完成 LightGBM profile 调参。第二层进行 full scale-up，确认样本量扩大能稳定提升 clean performance。第三层做频域优先提分，比较 color_freq、multiscale_freq、block_dct、residual_freq 和 fusion_freq，并尝试 hierarchical、pairwise OVO 和 binary expert ensemble。第四层固定最终最佳模型，不重新训练，只在 validation 图像上施加 JPEG、resize 和 Gaussian noise，诊断模型对真实后处理扰动的脆弱性。

所有主要结果通过 metrics_summary.json、model_comparison.csv、混淆矩阵、feature importance 和 robustness CSV 自动汇总到 report/tables 与 report/figures。Notebook 只读取这些资产，不重新执行大规模训练。

5 Results and Analysis

5.1 Clean Performance

表 2 汇总了从旧灰度 baseline 到第二轮频域融合优化的关键结果。第一轮 full baseline 的双任务平均 macro-F1 为 0.9042；引入 fusion_freq 后，5% 抽样已经达到 0.9919，full 训练比例进一步达到 0.9952。队友补充的 20% seed 123 实验也达到 0.9931，说明该提升不是单个 seed 的偶然现象。




Figure 1: 第二轮频域优化和抽样比例扩大带来的 clean performance 提升。

Table 2: 主要 clean 结果对比。

Run	Feature	Binary F1	Attr. F1	Avg. F1
旧 full baseline	gray FFT/DCT	0.8997	0.9086	0.9042
v2 5% flat	fusion	0.9871	0.9967	0.9919
v2 20% flat	fusion	0.9910	0.9973	0.9942
v2 20% seed123	fusion	0.9892	0.9971	0.9931
v2 full best	fusion	0.9913	0.9991	0.9952

Table 3: 20% validation 上的鲁棒性诊断 macro-F1。

Setting	Binary	Attribution	Note
clean	0.9908	0.9992	无扰动
JPEG 95	0.6607	0.2952	轻压缩
JPEG 50	0.5666	0.2526	强压缩
resize 0.5	0.3671	0.1551	下采样
resize 1.5	0.8136	0.6282	上采样
noise 2	0.7481	0.1887	轻噪声
noise 10	0.3377	0.1000	强噪声

5.2 Confusion Matrix and Feature Importance

最终 full 模型在 48000 张二分类 validation 图像上只误判 420 张；在 24000 张 AI attribution validation 图像上只误判 22 张。归因任务中 ADM、BigGAN、VQDM 和 GLIDE 基本都能被稳定区分，说明颜色频谱、多尺度频谱和残差频谱对生成源差异尤其敏感。

5.3 Robustness Diagnosis

鲁棒性实验不重新训练模型，而是直接加载 outputs_v2_full_best 的最佳模型，对同一 20% validation 子集施加扰动。表 3 显示，fusion_freq 模型在 clean 子集上接近满分，但 JPEG、resize 和

Gaussian noise 会显著改变高频与颜色频谱统计，从而造成预测分布偏移。例如二分类在 JPEG 95 下从 0.9908 降到 0.6607，在 resize 0.5 下降到 0.3671，在 noise 10 下降到 0.3377；归因任务对 degraded 图像更加敏感。

旧灰度 baseline 的 clean 二分类 macro-F1 只有 0.8942，但在 JPEG 95 和 noise 2 下分别保持 0.8686 和 0.8460，高于 fusion_freq 的 0.6607 和 0.7481。这一对照说明：频域融合特征显著提升 clean 判别力，但也更依赖易被后处理破坏的细粒度




Figure 2: 最终 full 模型在生成源归因任务上的混淆矩阵。




Figure 3: 二分类任务中的 Top-20 频域特征重要性。

频谱指纹。本文因此不声称鲁棒性已经解决，而是将 degraded evaluation 作为失效模式分析。

6 Discussion

实验结果显示，AIGC 图像与真实图像在频率域中存在强可分模式。尤其是颜色频谱、多尺度功率谱和残差频谱，使浅层模型在四生成源 clean validation 上接近饱和。由于模型特征具有明确物理含义，特征重要性、混淆矩阵和频谱示例可以解释模型关注的频段和通道。

主要局限也很明确。第一，本文只使用 GenImage 四个生成源，不声明完整 GenImage benchmark。第二，模型是浅层频域检测器，不与大规模深度检测器争夺 SOTA。第三，鲁棒性结果表明，强 JPEG、缩放和噪声会破坏当前最有效的高频/颜色指纹；如果后续目标是部署到真实社交媒体图像，应进一步研究训练时扰动增强、测试时增强或更稳健的低频/中频特征融合。

7 Conclusion

本文将 AIGC 图像检测转化为可解释的频域统计挖掘问题。最终 fusion_freq full 模型在 clean validation 上达到二分类 macro-F1 0.9913 和归因 macro-F1 0.9991，显著超过早期灰度 FFT/DCT baseline。鲁棒性诊断进一步指出，clean 性能和 degraded 稳定性之间存在明显权衡：频谱融合特征可以大幅提升检测能力，但对后处理扰动敏感。该结论为课程项目提供了完整的检测、归因、解释和失效分析闭环。

References

- [1] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. 2017. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In *Advances in Neural Information Processing Systems*.
- [2] Alan V. Oppenheim, Ronald W. Schaffer, and John R. Buck. 1999. *Discrete-Time Signal Processing*. Prentice Hall.
- [3] Mingjian Zhu, Hanting Chen, Qiangyu Yan, Xudong Huang, Guanyu Lin, Wei Li, Zhijun Tu, Hailin Hu, Jie Hu, and Yunhe Wang. 2023. GenImage: A Million-Scale Benchmark for Detecting AI-Generated Image. arXiv:2306.08571 [cs.CV]




Figure 4: 当前 fusion_freq 最佳模型与旧灰度 baseline 的 degraded validation 对照。